

Réponses aux Exercices Théoriques et Conceptuels

Masterclass Machine Learning Prédictif

Compte Rendu

Table des matières

1	TP2 : Clustering par K-Means	2
1.1	Exploration et Qualité des données	2
1.2	Analyse visuelle initiale	2
1.3	Méthode du Coude (Elbow Method)	2
1.4	Profilage Métier des Clusters	2
2	TP : Machine Learning Classification	2
2.1	Interprétation des Métriques (Précision vs Rappel)	2
2.2	Importance de la séparation Train/Test	3
3	TP4 : XGBoost et Validation Set	3
3.1	Dynamique du Learning Rate	3
3.2	Early Stopping et Set de Validation	3
4	TP : Régression, Cross-Validation et Complexité	3
4.1	Classification vs Régression	3
4.2	Interprétation de la Validation Croisée (CV)	3
4.3	Contrôle de Complexité (Biais vs Variance)	3
5	TPs 6 : Séries Temporelles (De l'Exploration au ML)	4
5.1	Exploration et Imputation	4
5.2	Décomposition et Stationnarité	4
5.3	ARIMA vs Machine Learning	4
6	TP7 : XGBoost, Objectifs et Métriques	4
6.1	Alignement Mathématique vs Métier	4
6.2	Distribution de Poisson et Tweedie	4
7	TP8 : Préparation avancée et Cas Déséquilibrés	5
7.1	Sélection de Variables (Feature Selection)	5
7.2	Fuite de données (Data Leakage) et Pipelines	5
7.3	Traitement des Outliers	5
7.4	Classification Déséquilibrée	5

1 TP2 : Clustering par K-Means

1.1 Exploration et Qualité des données

L'interprétation des statistiques descriptives (`df.describe()`) permet de vérifier la cohérence des échelles (ex : le score de dépense est bien borné entre 1 et 100). L'absence de valeurs nulles confirme que nous pouvons appliquer K-Means directement sans imputation préalable, l'algorithme étant sensible aux distances euclidiennes qui requièrent des données complètes.

1.2 Analyse visuelle initiale

Avant même d'appliquer l'algorithme, le nuage de points (Revenu vs Score de dépense) laisse souvent apparaître des regroupements naturels (ex : un groupe au centre, et quatre groupes aux extrémités formant une croix). Cela confirme la pertinence d'une approche de clustering.

1.3 Méthode du Coude (Elbow Method)

L'inertie (somme des carrés des distances intra-cluster) diminue mécaniquement à mesure que k augmente. Le "coude" identifie le point d'inflexion où l'ajout d'un cluster supplémentaire n'apporte plus de gain marginal significatif en termes de compacité. Pour ce dataset, le coude se situe généralement à $k = 5$.

1.4 Profilage Métier des Clusters

L'analyse des centroïdes permet de nommer les segments d'un point de vue marketing :

- **Économes** : Faible revenu, faible score de dépense.
- **Cibles / VIP** : Haut revenu, fort score de dépense.
- **Dépensiers** : Faible revenu, fort score de dépense (risque d'endettement).
- **Prudents** : Haut revenu, faible score de dépense.
- **Moyens** : Revenu moyen, score moyen (le groupe le plus dense).

2 TP : Machine Learning Classification

2.1 Interprétation des Métriques (Précision vs Rappel)

Dans une classification, le choix de la métrique dépend de l'objectif métier :

- **Le Rappel (Recall)** est privilégié si le coût d'un Faux Négatif est immense (ex : rater une tumeur maligne). On préfère alerter trop souvent (baisse de précision) plutôt que de rater un cas.
- **La Précision** est privilégiée si le coût d'un Faux Positif est élevé (ex : bloquer légitimement la carte bancaire d'un client).
- **Le Score F1** est la moyenne harmonique des deux, utile lorsque les classes sont déséquilibrées et que l'on cherche un modèle robuste globalement.

2.2 Importance de la séparation Train/Test

Le modèle s'ajuste sur le *Train set*. Si on l'évaluait sur ces mêmes données, on mesurerait sa capacité de mémorisation (surapprentissage/overfitting) et non sa capacité de généralisation. Le *Test set* agit comme un juge impartial simulant des données futures.

3 TP4 : XGBoost et Validation Set

3.1 Dynamique du Learning Rate

Le `learning_rate` (taux d'apprentissage) contrôle le pas de correction de chaque nouvel arbre.

- **S'il est trop élevé** (ex : 0.3), le modèle fait de grands sauts et peut diverger ou s'arrêter prématurément sans trouver l'optimum.
- **S'il est trop faible** (ex : 0.01), le modèle apprend de façon très fine mais nécessite un nombre d'arbres (`n_estimators`) gigantesque pour converger, augmentant le temps de calcul.

3.2 Early Stopping et Set de Validation

Un modèle XGBoost va naturellement surapprendre si on le laisse créer des arbres à l'infini. En surveillant une métrique sur un **Set de Validation** externe, l'*early stopping* arrête l'entraînement dès que l'erreur de validation remonte (inflexion de la courbe), garantissant que le modèle final (à l'itération `best_iteration`) a la meilleure capacité de généralisation.

4 TP : Régression, Cross-Validation et Complexité

4.1 Classification vs Régression

La **Classification** prédit une catégorie discrète (ex : Churn vs Non-Churn), évaluée par le taux de bonnes prédictions. La **Régression** prédit une quantité continue (ex : le prix d'un appartement immobilier), évaluée par la distance entre la prédiction et la réalité (MAE, RMSE).

4.2 Interprétation de la Validation Croisée (CV)

Scikit-learn maximise toujours ses métriques de *scoring*. Puisque la RMSE est une erreur (qui doit être minimisée), scikit-learn renvoie la *Negative RMSE*. Il faut multiplier les scores par -1 pour retrouver l'erreur réelle dans l'unité cible. La CV permet d'obtenir une moyenne plus robuste de l'erreur qu'un simple Train/Test, particulièrement sur de petits datasets.

4.3 Contrôle de Complexité (Biais vs Variance)

L'hyperparamètre `max_depth` illustre parfaitement le compromis Biais/Variance :

- **Sous-apprentissage (Biais élevé)** : Un arbre trop peu profond (ex : 2) ne capte pas les subtilités des données (modèle simpliste).

- **Surapprentissage (Variance élevée)** : Un arbre trop profond (ex : 15) mémorise le bruit statistique de l'échantillon d'entraînement. Sur un jeu de test, son erreur explosera.

5 TPs 6 : Séries Temporelles (De l'Exploration au ML)

5.1 Exploration et Imputation

La méthode `ffill` (forward fill) repose sur l'hypothèse que la demande (ou la température) reste stable entre deux heures manquantes. C'est une heuristique physiquement réaliste à très court terme.

5.2 Décomposition et Stationnarité

- **Modèle Additif vs Multiplicatif** : Si l'amplitude des pics saisonniers augmente proportionnellement à la tendance de fond, le modèle multiplicatif s'impose.
- **Test ADF** : Si la *p-value* est inférieure à 0.05, on rejette l'hypothèse de racine unitaire : la série est stationnaire.
- **Différenciation** : Si la série ne l'est pas, la différenciation d'ordre 1 ($Y_t - Y_{t-1}$) retire la tendance, et la différenciation saisonnière ($Y_t - Y_{t-24}$) retire les cycles, stabilisant ainsi la moyenne.

5.3 ARIMA vs Machine Learning

- **ARIMA** : Modélisation statistique pure. Excellent pour capturer l'autocorrélation linéaire à court terme, mais difficile à paramétrer face à des saisonnalités multiples (jour/semaine/année) sans passer par des modèles complexes (SARIMAX).
- **Modèles ML Supervisés (XGBoost/RF)** : Transforment le problème temporel en tableau classique via la création de "Lags" et de moyennes mobiles. Ils gèrent nativement les non-linéarités et l'ajout massif de variables exogènes (Météo, Jours fériés), mais nécessitent une maintenance lourde (recalcul constant des *rolling features* en production).

6 TP7 : XGBoost, Objectifs et Métriques

6.1 Alignement Mathématique vs Métier

Il est fondamental de séparer l'*Objective Function* (ce que l'algorithme optimise, ex : LogLoss, RMSE, Poisson) et l'*Evaluation Metric* (ce que l'humain surveille). L'objectif doit être continûment dérivable (gradients/hessiens), tandis que la métrique de monitoring (ex : F1-score, MAPE) est souvent discrète ou interprétable en pourcentages.

6.2 Distribution de Poisson et Tweedie

Pour des prédictions de "comptages" (ex : sinistres, visites), la distribution Normale (RMSE) est inadaptée car elle peut produire des prédictions négatives. Les objectifs `count:poisson` ou `reg:tweedie` modélisent des masses à zéro et des queues lourdes, et

appliquent une transformation log/exponentielle qui garantit une prédiction strictement positive.

7 TP8 : Préparation avancée et Cas Déséquilibrés

7.1 Sélection de Variables (Feature Selection)

L'ajout non contrôlé de variables engendre la malédiction de la dimensionnalité.

- **Lasso (L1)** : Réduit mathématiquement à zéro les coefficients des variables corrélées ou peu utiles (modèle épars).
- **Random Forest** : Évalue l'importance par la réduction de l'impureté aux nœuds.
- **Note** : Sur XGBoost, la sélection préalable est souvent superflue car le boosting pénalise nativement les arbres complexes.

7.2 Fuite de données (Data Leakage) et Pipelines

Toute transformation nécessitant un apprentissage (calcul d'une moyenne pour un *Scaler*, calcul de proportions pour un *TargetEncoder*, imputation) doit se faire **uniquement sur le fold d'entraînement** au sein d'une validation croisée. Imputer la médiane sur l'ensemble du dataset avant le `train_test_split` constitue une fuite d'informations du futur. Scikit-learn Pipeline évite cela structurellement.

7.3 Traitement des Outliers

- **Méthodes** : L'IQR est plus robuste que le Z-Score face à des distributions asymétriques. *Isolation Forest* isole rapidement les anomalies dans les espaces multidimensionnels.
- **Traitement** : La suppression réduit la taille des données. Le "Capping" (Winsorisation) ou la transformation logarithmique préservent la donnée tout en réduisant mécaniquement l'effet levier de la valeur extrême sur l'hyperplan des modèles linéaires.

7.4 Classification Déséquilibrée

Face à un dataset avec 99% d'une classe A et 1% d'une classe B, un modèle naïf prédisant toujours A aura 99% d'*Accuracy* : cette métrique est donc trompeuse.

- **SMOTE** : Crée des données synthétiques par interpolation dans la classe minoritaire, augmentant la zone de décision.
- **Pondération** : `scale_pos_weight` dans XGBoost pénalise lourdement les erreurs sur la classe minoritaire lors du calcul du gradient, forçant le modèle à y prêter attention sans altérer la donnée d'origine.
- **Optimisation du seuil** : On décale la probabilité de décision (ex : à 0.3 au lieu de 0.5) pour maximiser le Rappel au détriment de la Précision, selon la matrice des coûts métiers.